

TEST TECHNIQUE DOCTORAL

ANALYSE MULTIMODALE DES DÉBATS POLITIQUES

Détection et classification multimodales de sophismes argumentatifs

Reproduction critique et extensions de MM-ArgFallacy2025

Auteur :
Moez KESSEMTINI

Article de référence :
Mancini *et al.*, ArgMining @ ACL 2025

Résumé

Ce rapport étudie la détection (AFD) et la classification (AFC) de sophismes argumentatifs dans les débats présidentiels américains, en texte, en audio et en multimodal, à partir du shared task MM-ArgFallacy2025 [18]. Nous en proposons d’abord une analyse critique (Partie A). Nous reproduisons ensuite, avec MAMKit [15], les six cellules *Baseline Transformer* du tableau officiel (RoBERTa, WavLM, fusion tardive) sur le jeu de test des débats 2024, avec trois graines aléatoires (Partie B). La reproduction a fait apparaître quatre défauts dans la chaîne de traitement, que nous avons corrigés : une métrique « macro » calculée en *micro*, des étiquettes AFD inversées sur le test, une recherche de configuration instable et une dépendance des résultats à l’état du générateur aléatoire. Une fois ces défauts corrigés, nos scores sont dans l’intervalle de variabilité entre graines des scores publiés. Cette variabilité est du même ordre que la plupart des écarts que l’article interprète.

Une exploration des données montre un décalage marqué entre l’entraînement et le test : la distribution des classes change, les segments du test sont deux fois plus courts, et aucun descripteur prosodique ne distingue les classes une fois normalisé par débat. Les extensions de la Partie C (fine-tuning, quatre stratégies de déséquilibre, contexte dialogique, apprentissage multi-tâche, cinq mécanismes de fusion avec recherche du taux d’apprentissage, cascade parole→texte et distillation intermodale texte→audio) convergent : l’audio ne contient pas d’information acoustique efficacement exploitable au-delà du texte. En revanche, son contenu *lexical* suffit : transcrit par Whisper puis classé par le modèle texte, l’audio seul atteint 0,380 en AFC, contre 0,189 pour la meilleure représentation acoustique et 0,356 pour le meilleur système audio du shared task. Le contexte dialogique, moyenné avec la phrase cible dans un encodeur gelé, dilue celle-ci et dégrade significativement la classification ; un contrôle qui ne moyenne que la cible annule l’essentiel de la baisse, sans faire apparaître de gain. Le fine-tuning de l’encodeur texte n’améliore que la détection. La distillation texte→audio, évaluée avec deux contrôles et un test apparié, ne dépasse pas une simple moyenne des représentations WavLM figées. Six méthodes d’explicabilité, évaluées par leur fidélité, montrent que l’attention explique mal les décisions, et que le modèle prédit *Ad Hominem* sur la simple mention de l’adversaire. Nous en tirons des recommandations de protocole (variance entre graines, tests appariés, validation) et des perspectives futures .

Mots-clés : argument mining multimodal, sophismes, reproductibilité, fusion multimodale, déséquilibre des classes, distillation intermodale.

Table des matières

1	Introduction	1
2	Analyse critique de MM-ArgFallacy2025	1
2.1	Contributions de l'article	1
2.2	Lecture des résultats par modalité	1
2.3	Pourquoi la multimodalité apporte peu	2
2.4	Rôle du déséquilibre des classes	3
2.5	Positionnement dans l'état de l'art	3
3	Protocole expérimental	3
3.1	Données et découpage	3
3.2	Modèles et hyperparamètres	4
3.3	Gestion du déséquilibre	4
3.4	Métriques et analyse statistique	4
3.5	Défauts trouvés dans la chaîne de traitement	4
4	Exploration des données	4
4.1	Décalage entre l'entraînement et le test	5
4.2	Prosodie : aucun signal de classe	5
4.3	Qualité de l'alignement texte–audio	5
5	Reproduction des baselines	6
5.1	Scores obtenus et scores publiés	6
5.2	Absence de gain multimodal	6
5.3	Analyse par classe	6
6	Extensions méthodologiques	7
6.1	Fine-tuning de l'encodeur et stratégies de déséquilibre	7
6.2	Contexte dialogique ($n-1$, $n-2$)	7
6.3	Apprentissage multi-tâche avec la détection de phrases argumentatives	8
6.4	Mécanismes de fusion	8
6.5	Audio seul par cascade parole $\rightarrow$ texte	9
6.6	Proposition : distillation intermodale texte $\rightarrow$ audio	9
6.7	Explicabilité du classifieur texte	10
7	Discussion, limites et perspectives	11
7.1	Synthèse	11
7.2	Limites	12
7.3	Perspectives	12
7.4	Conclusion	12
A	Code source et reproduction	14
B	Compléments	14
B.1	Défauts de la chaîne de traitement	14
B.2	Exploration : prosodie et alignement	15
B.3	Pseudo-code de la distillation texte $\rightarrow$ audio	15
B.4	Explicabilité : fidélité, lexique et exemples	16

1 Introduction

Un sophisme est un raisonnement d'apparence valide mais fallacieux : attaque contre la personne plutôt que contre l'argument, appel à l'émotion, fausse causalité, etc. Leur repérage automatique dans le discours politique relève de l'*argument mining*. Il est utile à l'analyse des stratégies rhétoriques, à la vérification des faits et à l'éducation au débat. Le shared task MM-ArgFallacy2025 [18] pose ce problème sur des débats présidentiels américains dont chaque phrase est disponible en texte et en audio aligné. Il définit deux sous-tâches :

- **AFD** (*Argumentative Fallacy Detection*) : décider si une phrase contient un sophisme ; métrique : F1 binaire de la classe positive.
- **AFC** (*Argumentative Fallacy Classification*) : attribuer à un segment fallacieux l'une des six catégories de [9] (*Appeal to Emotion, Appeal to Authority, Ad Hominem, False Cause, Slippery Slope, Slogans*) ; métrique : F1 macro.

Chaque sous-tâche est évaluée dans trois modes d'entrée : texte seul, audio seul et texte+audio.

Démarche et contributions. Ce rapport couvre les parties suivantes :

1. **Analyse critique** de l'article (chapitre 2) : contributions, lecture des résultats par modalité, causes du faible apport de l'audio, rôle du déséquilibre et positionnement dans l'état de l'art.
2. **Reproduction** des six cellules *Baseline Transformer* (texte, audio et texte+audio, pour AFD et AFC) avec MAMKit, sur le jeu de test officiel et avec trois graines (chapitres 3 et 5).
3. **Exploration des données** (chapitre 4) : décalage entre l'entraînement et le test, prosodie et audit de l'alignement texte-audio par transcription automatique.
4. **Extensions** (chapitre 6) : fine-tuning et quatre stratégies de déséquilibre, contexte dialogique, apprentissage multi-tâche, cinq mécanismes de fusion, cascade parole→texte, une proposition originale de distillation intermodale texte→audio évaluée avec des contrôles dédiés, et une explicabilité *évaluée* (fidélité, stabilité) du classifieur texte.

Le code et les instructions de reproduction sont fournis dans le dépôt Git qui accompagne ce rapport (https://github.com/Moez2kessemtini/MM_argfallacy_implementation, annexe A).

2 Analyse critique de MM-ArgFallacy2025

2.1 Contributions de l'article

L'article [18] présente la première édition d'un shared task de détection et de classification *multimodales* de sophismes. Ses contributions sont les suivantes :

1. **Formulation** de deux sous-tâches (AFD, AFC) dans trois modes d'entrée. Le contexte dialogique (toutes les phrases précédentes du débat) est autorisé.
2. **Données d'entraînement** : MM-USED-Fallacy [17], soit 1 228 segments fallacieux AFC et 16 750 phrases AFD issus de 37 débats (1960–2020) annotés selon [9]. Des jeux auxiliaires (MM-USED, M-Arg, UKDebates) sont proposés pour l'apprentissage multi-tâche. L'alignement texte-audio est **refait avec WhisperX** [2], ce qui réintègre des débats auparavant écartés.
3. **Un jeu de test secret** construit à partir des deux premiers débats de 2024 (Trump–Biden, Trump–Harris) : 229 sophismes et 1 946 phrases non fallacieuses. Deux annotateurs ont travaillé avec un accord modéré ($\kappa = 0,48$ en AFD et $0,50$ en AFC ; $0,22$ seulement pour *False Cause*).
4. **Des baselines** (BiLSTM GloVe/MFCC et Transformer RoBERTa/WavLM, fusion tardive par concaténation), toutes distribuées via MAMKit [15], qui reconstruit les jeux audio malgré les contraintes de droits.
5. **Une synthèse des cinq systèmes participants** et de leurs leviers : augmentation par LLM, contexte, pertes adaptées, différentes fusions.

2.2 Lecture des résultats par modalité

Le tableau 2.1 reprend le tableau 4 de l'article. Nous y ajoutons une ligne absente de l'article : le score d'un **classifieur trivial** sur le même jeu de test. En AFD, prédire « sophisme » partout donne un F1 de $2\pi/(1+\pi) = 0,190$, avec $\pi = 229/2175$. En AFC, prédire toujours *Appeal to Emotion* donne un F1 macro de $0,153$.

Système	AFC (F1 macro)			AFD (F1 binaire)		
	Texte	Audio	Texte+audio	Texte	Audio	Texte+audio
Meilleur participant	0,4856	0,3559	0,4611	0,2534	0,2095	0,2244
Baseline BiLSTM	0,4721	0,1582	0,2191	0,2462	0,0000	0,2337
Baseline Transformer	0,3925	0,0643	0,3816	0,2770	0,0000	0,2848
Classifieur trivial (ajouté)	0,153	0,153	0,153	0,190	0,190	0,190

Table 2.1 – Résultats publiés sur le test secret 2024. La dernière ligne correspond au classifieur constant le plus favorable, que nous avons calculé.

Texte. Le texte domine dans les deux tâches. La *baseline* BiLSTM avec GloVe (0,472) dépasse le Transformer avec RoBERTa gelé (0,393) en AFC, et un seul participant bat les baselines texte. Le Transformer est donc loin d’être saturé : son encodeur reste gelé et seule une petite tête est entraînée sur environ un millier d’exemples. En AFD, le meilleur F1 (0,28) ne dépasse le classifieur trivial (0,19) que de 0,09 : la détection reste un problème largement ouvert.

Audio. Les scores audio des deux baselines sont dégénérés. En AFD, le F1 est nul : le modèle ne prédit jamais la classe positive. En AFC, le Transformer audio (0,064) fait *moins bien* que le classifieur constant, et le BiLSTM (0,158) l’égale. L’article présente le gain des participants sur ces baselines comme un « progrès audio ». Une partie de ce gain correspond en fait au simple passage au-dessus d’un classifieur trivial. Seul le meilleur système audio AFC (HuBERT, 0,356) s’en écarte nettement. Nous montrons au chapitre 6 qu’une simple moyenne de WavLM gelé avec un classifieur linéaire équilibré atteint déjà 0,19, et qu’une cascade transcription→texte atteint 0,38 à partir de l’audio seul.

Multimodal. La lecture système par système est plus sévère que celle de l’article. Dans **7 des 9 couples** (système, tâche) du tableau 4 de l’article, le score texte+audio est *inférieur* au score texte du même système. Il lui est égal pour CASS en AFC (dont le score texte, 0,143, est d’ailleurs sous le classifieur trivial), et supérieur seulement pour le Transformer en AFD (+0,008). L’article note que deux équipes dépassent la baseline multimodale, mais aucune ne dépasse son propre modèle texte.

Fiabilité des comparaisons. Chaque système est évalué sur un seul entraînement, sans variance ni test de significativité. Or le test AFC ne compte que 229 segments, dont 9 *Slogans* et 16 *False Cause* ou *Appeal to Authority*. Un seul *Slogan* correctement classé de plus fait varier le F1 de cette classe d’environ 0,1, donc le F1 macro d’environ 0,02. Nous mesurons au chapitre 5 une variabilité entre graines qui atteint 0,04. Plusieurs écarts commentés dans l’article sont inférieurs à cette valeur (0,011 entre le texte et le texte+audio du Transformer en AFC, par exemple). Ils ne sont donc pas interprétables. Enfin, la définition du F1 macro n’est pas précisée. La classe *Slippery Slope* est absente du test : un système qui la prédit voit une classe à F1 nul entrer dans la moyenne, ce qui le pénalise par rapport à un système qui ne la prédit jamais.

2.3 Pourquoi la multimodalité apporte peu

L’article avance trois explications : des indices acoustiques trop subtils, une dépendance au locuteur et des fusions trop simples. Nous en ajoutons quatre, que nos expériences permettent en partie de tester :

1. **Les étiquettes sont définies par le texte.** L’annotation, faite sur les transcriptions, ne tient pas compte de l’audio, comme l’admet la section *Limitations* de l’article. Un sophisme est une propriété logique et sémantique du contenu. Même si la prosodie accompagne une stratégie rhétorique, elle ne participe pas à la définition des étiquettes, donc rien n’impose qu’elle permette de les prédire.
2. **L’encodeur audio est redondant avec le texte.** Le checkpoint WavLM des baselines¹ est affiné pour la reconnaissance de la parole sur LibriSpeech. Ses représentations sont donc orientées vers le contenu *phonétique et lexical*, que RoBERTa encode déjà, plutôt que vers la prosodie.
3. **Il y a trop peu de données pour l’espace audio.** Environ 1 000 exemples AFC pour une séquence de vecteurs de dimension 768 par segment : la tête audio sur-apprend ou s’effondre sur une classe, ce qui explique les scores triviaux du tableau 2.1. Notre contrôle « élève supervisé » (section 6.6) confirme qu’entraîner sur ces étiquettes dégrade WavLM.

1. [patrickvonplaten/wavlm-libri-clean-100h-base-plus](https://github.com/patrickvonplaten/wavlm-libri-clean-100h-base-plus)

4. **La fusion par concaténation permet d’ignorer l’audio.** La modalité la plus prédictive domine le gradient, et la tête fusionnée se comporte comme une tête texte bruitée. Nous vérifions avec cinq fusions plus riches (section 6.4) qu’en l’absence de signal audio, changer l’architecture ne crée pas de gain.

Notre exploration (chapitre 4) appuie les points 1 et 3 : une fois normalisés par débat, aucun descripteur prosodique ne distingue les classes.

2.4 Rôle du déséquilibre des classes

Le déséquilibre est double : 7 à 10 % de phrases fallacieuses en AFD, et 62 % d’*Appeal to Emotion* contre 3 % de *Slogans* en AFC. Il agit à trois niveaux. Sur l’**optimisation**, d’abord : sans pondération, prédire la majorité est un minimum stable, d’où les F1 audio nuls ; avec la pondération par l’inverse des fréquences des baselines, toutes les prédictions constantes ont une perte voisine, sans que cela crée de signal discriminant. Sur la **métrique**, ensuite : le F1 macro donne à 9 *Slogans* le poids de 142 *Appeal to Emotion*, si bien que le classement dépend de quelques exemples rares. Par le **décalage de distribution**, enfin : *Ad Hominem* passe de 11,8 à 20,1 % entre l’entraînement et le test, *Appeal to Authority* de 15,5 à 7,0 %, *Slippery Slope* de 3,7 à 0 %, et la proportion de sophismes AFD de 7,2 à 10,5 %. Des poids calculés sur l’entraînement sont donc mal calibrés pour le test (section 4.1). L’article conclut que l’augmentation par LLM est « plus efficace que les ajustements algorithmiques », mais sur la foi d’une seule équipe et d’un seul entraînement, sans ablation contrôlée. Nous comparons quatre stratégies à protocole identique en section 6.1.

2.5 Positionnement dans l’état de l’art

Argument mining multimodal. Lippi et Torroni [12] ont montré les premiers, sur un débat britannique, que des descripteurs acoustiques aident à détecter les *claims*. MM-USED [16] et M-Arg [20] ont étendu ce travail aux débats américains, pour la détection et la classification de composants et de relations argumentatives. L’audio y apporte des gains modestes mais réels [19]. Pour les sophismes, l’essentiel de la littérature reste textuel : classification dans les débats présidentiels [9, 8], sophismes logiques en général [10]. Mancini *et al.* [17] ont introduit la version multimodale du problème. MM-ArgFallacy2025 en est la première évaluation communautaire sur un test indépendant.

Apport et limites. Le shared task apporte un banc d’essai commun et reproductible, avec des données réalignées, un test temporellement disjoint (2024) et une boîte à outils. Il reste pourtant en retrait de l’état de l’art multimodal sur deux points. D’abord, toutes les fusions évaluées sont tardives ou par concaténation, alors que l’analyse multimodale du langage s’appuie depuis plusieurs années sur l’attention intermodale entre séquences non alignées [24]. Ensuite, l’unité d’analyse est la phrase isolée, sans locuteur ni dynamique d’interaction, alors que ce sont précisément les dimensions où l’audio a le plus de chances d’apporter une information propre. Pour une thèse sur la rhétorique politique, l’enjeu n’est donc pas seulement d’utiliser de meilleurs encodeurs. Il faut aussi des **annotations où l’audio participe à la définition de l’étiquette**, et des **protocoles d’évaluation qui rendent les gains mesurables** (plusieurs graines, tests appariés).

3 Protocole expérimental

3.1 Données et découpage

Les données sont téléchargées et construites avec MAMKit [15] (version GitHub, non modifiée). L’audio des 37 débats est récupéré depuis les sources d’origine, puis découpé en 19 293 extraits selon les horodatages fournis, soit 29,7 h. Les effectifs obtenus correspondent exactement à ceux de l’article : 1 228 + 229 segments en AFC, et 16 750 + 2 175 phrases en AFD.

Découpage officiel. Les démos de MAMKit utilisent une validation croisée *leave-one-debate-out* qui exclut les débats de 2024. Ce protocole n’est pas comparable au tableau 4. Nous utilisons le découpage du shared task : entraînement sur MM-USED-Fallacy, test sur les débats 47_2024 et 48_2024.

Validation. L’article ne précise pas comment la validation est construite. Nous retenons 4 débats d’entraînement *entiers*, tirés avec la graine, sur le modèle de MAMKit. Prendre des débats entiers évite que des phrases d’un même débat se retrouvent des deux côtés. La validation sert à l’arrêt précoce et à la sélection du meilleur checkpoint. Le test n’est jamais utilisé pour une sélection.

3.2 Modèles et hyperparamètres

Nous reproduisons la *Baseline Transformer* avec les configurations MAMKit `anonymous`, sans modification :

- **Texte** : RoBERTa-base [13] *gelé*, représentation moyennée, puis une tête MLP.
- **Audio** : WavLM base+ [5] (`patrickvonplaten/wavlm-libri-clean-100h-base-plus`) *gelé*, trames sous-échantillonnées d'un facteur 5, puis une couche d'encodeur Transformer et une tête.
- **Texte+audio** : fusion tardive. Le vecteur RoBERTa (768) est concaténé à la sortie d'un BiLSTM appliqué aux trames WavLM (64), puis passé dans un MLP $832 \rightarrow 128 \rightarrow C$.

Entraînement : Adam avec un taux d'apprentissage de 10^{-3} , lots de 8 avec accumulation sur 3 pas, au plus 50 époques (texte) ou 20 (audio et texte+audio). Arrêt précoce avec une patience de 5 sur la perte de validation, et conservation du meilleur checkpoint. Seules les têtes sont entraînées.

3.3 Gestion du déséquilibre

Les baselines utilisent une entropie croisée pondérée par l'inverse des fréquences, avec les poids figés dans la configuration MAMKit : [0,54; 6,98] en AFD et [0,26; 1,05; 2,29; 3,20; 4,10; 5,18] en AFC. En section 6.1, nous comparons à protocole identique quatre stratégies :

- (i) les poids de la configuration ;
- (ii) des poids $N/(K n_c)$ recalculés sur l'entraînement effectif, où N est le nombre d'exemples, K le nombre de classes et n_c l'effectif de la classe c ;
- (iii) la *focal loss* [11] ($\gamma = 2$), non pondérée pour isoler son effet ;
- (iv) un échantillonnage équilibré (`WeightedRandomSampler`) avec une entropie croisée non pondérée.

Une seule correction est appliquée à la fois, pour que leurs effets ne se cumulent pas.

3.4 Métriques et analyse statistique

En AFD, nous mesurons le F1 de la classe positive. En AFC, nous mesurons le F1 macro sur les classes présentes dans la vérité terrain ou les prédictions, selon la convention de scikit-learn. Chaque configuration est entraînée avec **3 graines** (42, 2024, 666). Nous rapportons la moyenne et l'écart-type, ainsi que les scores par graine quand ils éclairent l'analyse. La graine fixe à la fois l'initialisation et le tirage des débats de validation.

Les comparaisons entre deux systèmes reposent sur un **bootstrap apparié** du test [7, 3]. Les deux systèmes sont rééchantillonnés sur les mêmes indices, 10 000 fois. Nous rapportons la différence de F1, moyennée sur les graines communes, son intervalle de confiance à 95 % et sa p -valeur bilatérale.

3.5 Défauts trouvés dans la chaîne de traitement

La reproduction a mis au jour quatre défauts, détaillés en annexe (tableau B.1). Tous sont corrigés dans notre code, sans modifier MAMKit lui-même :

1. le F1 « macro » de `torchmetrics` est calculé en *micro* par défaut, donc égal à l'*accuracy*, y compris dans les démos AFC ;
2. les phrases non fallacieuses de 2024 ont `fallacy = NaN`, si bien que le test `is not None` les étiquette « sophisme » : 2 160 positifs AFD au lieu de 229 ;
3. le hachage de `ConfigKey` dépend de l'ordre d'un `set`, d'où des `KeyError` aléatoires ;
4. le chargement de WavLM consomme le générateur aléatoire, si bien que les résultats audio dépendaient de l'état du cache (AFC audio : 0,067 contre 0,124).

Les deux premiers changent directement les chiffres publiables.

Reproductibilité. Les représentations WavLM gelées sont mises en cache sur disque (3,3 Go). Le cache produit exactement les mêmes résultats qu'un calcul direct, puisque la graine est fixée à nouveau après le prétraitement. Les scores texte sont identiques à la quatrième décimale entre toutes les versions de la chaîne. Les prédictions de test sont sauvegardées pour chaque graine, ce qui permet de refaire a posteriori toutes les analyses par classe et tous les tests appariés.

4 Exploration des données

Avant de modéliser, nous avons analysé la version des données utilisée (réalignée avec WhisperX) sous trois angles : les étiquettes et le texte, l'audio et la prosodie, et l'alignement texte-audio. Les scripts et toutes les sorties se trouvent dans `data_exploration/` du dépôt.

4.1 Décalage entre l’entraînement et le test




Figure 4.1 – Distribution des classes à l’entraînement (débat 1960–2020) et au test (2024) ; les valeurs sur les barres sont des effectifs.

Le test n’est pas tiré de la même distribution que l’entraînement (figure 4.1).

- **Distribution des classes.** *Ad Hominem* passe de 11,8 à 20,1 % et *Appeal to Authority* de 15,5 à 7,0 %. *Slippery Slope* disparaît (46 exemples d’entraînement, 0 au test). La proportion de sophismes en AFD passe de 7,2 à 10,5 %.
- **Longueur des segments.** Les segments du test sont nettement plus courts. En AFC, la longueur médiane passe de 21 à 11,5 mots pour *Appeal to Emotion*, de 32,5 à 8,5 pour *False Cause* et de 12,5 à 9 pour *Slogans*. En AFD, elle passe de 13 à 9 mots. Les durées audio suivent la même tendance. La segmentation des débats de 2024 diffère donc de celle du corpus d’origine. Les modèles rencontrent ainsi au test un décalage de covariables qu’aucune validation tirée des débats d’entraînement ne peut anticiper.
- **Poids de classes.** Les poids figés dans la configuration MAMKit ne correspondent pas à l’entraînement actuel. Celui d’*Ad Hominem* vaut 2,29, contre 1,41 si on recalcule l’inverse des fréquences. Ce décalage est cohérent avec la sur-prédiction d’*Ad Hominem* que nous observons (section 5.3).

Par ailleurs, le taux de sophismes varie de 2,3 à 16,8 % d’un débat à l’autre, et les débats 2016–2020 sont les plus fallacieux. Les fuites entre l’entraînement et le test sont négligeables : 36 phrases AFD du test (1,7 %), toutes génériques (« thank you »), figurent aussi dans l’entraînement, et aucun segment AFC n’est dupliqué. Le contexte de trois phrases précédentes plus la cible tient en 296 tokens au plus : RoBERTa n’a donc jamais besoin de tronquer. Le jeu de données ne fournit aucun identifiant de locuteur, ce qui exclut une modélisation directe du locuteur.

4.2 Prosodie : aucun signal de classe

Pour chaque segment AFC, nous avons extrait huit descripteurs prosodiques : durée, débit, taux de pauses, moyenne et écart-type de l’énergie, F0 médiane, étendue de F0 et proportion de trames voisées. La F0 est estimée par autocorrélation normalisée. Les descripteurs sont normalisés *par débat*, ce qui retire en partie les effets de locuteur et de conditions d’enregistrement.

Après cette normalisation, aucun descripteur ne distingue les classes (test de Kruskal–Wallis, $\varepsilon^2 < 0,005$, $p > 0,05$). La seule exception est la durée ($\varepsilon^2 = 0,024$, effet faible), qui n’est qu’un indicateur indirect de la longueur du texte (figure B.1 en annexe). La F0 brute, elle, semble discriminante ($p = 2 \cdot 10^{-6}$), mais cet effet disparaît après normalisation ($p = 0,06$). Ce qui paraissait être un signal de classe provenait en fait de la composition locuteur/débat. Ce résultat appuie l’hypothèse de la section 2.3 : dans ces données, la prosodie seule ne contient pratiquement pas d’information sur la catégorie de sophisme.

4.3 Qualité de l’alignement texte–audio

Nous avons transcrit les 1 441 extraits AFC avec Whisper-medium [22], puis comparé chaque transcription au texte annoté. Le rappel est la part des mots annotés retrouvés dans la transcription, et la précision la part des mots transcrits présents dans l’annotation. Chaque extrait est classé *aligné*, *audio trop long*, *audio tronqué* ou *discordant* (figure B.2 en annexe).

Les résultats sont les suivants :

- 85,0 % des extraits sont alignés, 7,1 % ont un audio trop long, 5,7 % un audio tronqué et 2,3 % sont discordants.
- Le WER médian est nul et la similarité sémantique médiane vaut 0,994.
- Le test est mieux aligné que l’entraînement (90,4 contre 84,0 %).

Sur les segments très courts, une seule erreur de transcription suffit à faire sortir un extrait de la catégorie « aligné » : 15 % est donc une borne *haute* du taux de désalignement.

En conclusion, l’alignement fourni est de bonne qualité. Le faible apport de l’audio ne s’explique pas principalement par un désalignement, mais par l’absence d’information prosodique propre aux catégories de sophismes.

5 Reproduction des baselines

5.1 Scores obtenus et scores publiés

Tâche	Modalité	Article	Nous (moy. $\pm$ é.-t.)	Par graine (42 / 2024 / 666)	Écart
AFC (F1 macro)	Texte	0,3925	0,3885 $\pm$ 0,040	0,422 / 0,412 / 0,332	−0,004
	Audio	0,0643	0,1280 $\pm$ 0,043	0,067 / 0,164 / 0,153	+0,064
	Texte+audio	0,3816	0,3905 $\pm$ 0,016	0,413 / 0,379 / 0,379	+0,009
AFD (F1 binaire)	Texte	0,2770	0,2711 $\pm$ 0,005	0,273 / 0,276 / 0,264	−0,006
	Audio	0,0000	0,0000 $\pm$ 0,000	0 / 0 / 0	0
	Texte+audio	0,2848	0,2728 $\pm$ 0,004	0,271 / 0,278 / 0,270	−0,012

Table 5.1 – Reproduction de la *Baseline Transformer* sur le test secret 2024 (3 graines ; écart-type de population).

Discussion des écarts. Quatre des six cellules sont à moins d’un écart-type du score publié. La cellule audio AFD est identique, à zéro. Les deux écarts restants s’expliquent comme suit :

- **AFC audio (+0,064).** Le modèle audio est *instable* plutôt que différent. Avec la graine 42, il prédit toujours *Ad Hominem*, ce qui donne exactement 0,0669 (F1 de cette classe divisé par 5), un score proche de celui de l’article. Avec les deux autres graines, il obtient 0,16 et 0,15. Cette dernière valeur est égale, à la quatrième décimale près, au score du classifieur constant *Appeal to Emotion*. Selon la graine, la tête converge vers des prédictions dégénérées différentes. Le chiffre publié, issu d’un seul entraînement, correspond donc à l’un de ces états parmi d’autres.
- **AFD texte+audio (−0,012).** L’écart représente environ trois écarts-types, mais l’écart-type est très faible (0,004). Une différence de version des données ou de matériel suffit à le produire. À titre de comparaison, la proportion de positifs que nous mesurons sur l’ensemble AFD (7,6 %) diffère déjà de celle qu’annonce l’article (9,2 %).

Dans l’ensemble, **la reproduction est réussie**. Son principal enseignement est de nature méthodologique : la variabilité entre graines atteint 0,04 en AFC texte, ce qui dépasse la plupart des différences que l’article commente.

5.2 Absence de gain multimodal

Le texte+audio ne se distingue pas du texte seul : 0,3905 contre 0,3885 en AFC, et 0,2728 contre 0,2711 en AFD. Le bootstrap apparié le confirme : $\Delta = +0,002$ [−0,023 ; +0,025], $p = 0,88$ en AFC, et $+0,002$ [−0,012 ; +0,015], $p = 0,82$ en AFD. En AFC, la fusion réduit l’écart-type (0,016 contre 0,040) sans déplacer la moyenne. La branche audio agit donc comme un régularisateur ou un bruit, et non comme une source d’information. L’analyse par classe le confirme : par rapport au texte seul, ajouter l’audio dégrade légèrement *Appeal to Authority* et *Slogans*.

5.3 Analyse par classe

AFC, texte. Le F1 de *False Cause* est **nul** : sur les trois graines, 39 des 48 cas de test sont classés *Ad Hominem*. *Ad Hominem* est sur-prédit (102 prédictions pour 46 cas réels) et absorbe 32 % des *Appeal to Emotion*, ce qui est cohérent avec son poids surévalué dans la configuration (section 4.1). *Slogans* est la meilleure classe (F1 = 0,69). Ces segments courts et formulaires sont caractérisés par leur lexique. Enfin, *Slippery Slope*, absente du test, est prédite environ 8 fois par entraînement. Elle entre donc dans le F1 macro avec un score nul. Nous avons recalculé toutes les exécutions AFC en ne moyennant que les 5 classes présentes dans la vérité terrain : la baseline texte passe de 0,389 à 0,466, et le texte+audio de 0,391 à 0,469. La plupart des systèmes gagnent ainsi environ +0,08, un écart plus grand que toutes les différences entre systèmes de ce rapport. **La convention de calcul du F1 macro, que l’article ne précise pas, pèse donc davantage que le choix du modèle.**

AFD, texte. Le modèle prédit 465 positifs pour 229 réels (rappel 0,41, précision 0,20). Avec la pondération 0,54/6,98, le seuil de décision implicite est trop bas pour un test où la proportion de sophismes est plus élevée. Un seuil calibré sur la validation constituerait un gain peu coûteux.

6 Extensions méthodologiques

Toutes les extensions reprennent le protocole du chapitre 3 (découpage officiel, validation sur des débats entiers, trois graines). Chacune ne modifie qu'un facteur à la fois par rapport à une référence explicite. Nous présentons d'abord les leviers *texte* (fine-tuning et déséquilibre, contexte, multi-tâche), puis la *fusion*, l'*audio seul* (cascade et notre proposition de distillation) et enfin l'*explicitabilité*.

6.1 Fine-tuning de l'encodeur et stratégies de déséquilibre

Nous dégelons RoBERTa (taux d'apprentissage 10^{-5}) sans rien changer d'autre, puis nous comparons sur ce modèle les quatre stratégies de déséquilibre de la section 3.3 (tableau 6.1).

Configuration	AFC (F1 macro)	AFD (F1 binaire)
RoBERTa gelé, poids de la configuration	0,389 $\pm$ 0,040	0,271 $\pm$ 0,005
RoBERTa fine-tuné, (i) poids de la configuration	0,357 $\pm$ 0,080	0,297 $\pm$ 0,010
RoBERTa fine-tuné, (ii) poids recalculés sur l'entraînement	0,381 $\pm$ 0,043	0,301 $\pm$ 0,012
RoBERTa fine-tuné, (iii) <i>focal loss</i> $\gamma = 2$ non pondérée	0,351 $\pm$ 0,036	0,003
RoBERTa fine-tuné, (iv) échantillonnage équilibré	0,374 $\pm$ 0,019	0,263 $\pm$ 0,015
RoBERTa fine-tuné + WavLM, fusion tardive, (i)	0,357 $\pm$ 0,026	0,301 $\pm$ 0,006

Table 6.1 – Fine-tuning de l'encodeur texte et gestion du déséquilibre (3 graines).

En AFD, le fine-tuning aide (+0,026 [+0,003 ; +0,050], $p = 0,03$) : 16 750 exemples suffisent à adapter l'encodeur. En AFC, la contribution du fine-tuning reste limitée : avec environ 1 000 exemples, la variance explose (0,439, 0,382 et 0,249 selon la graine). Les **poids recalculés sur l'entraînement effectif** sont la meilleure stratégie en moyenne dans les deux tâches, mais sans différence significative avec les poids de la configuration (AFC +0,024, $p = 0,22$). La **focal loss non pondérée s'effondre en AFD** : avec un rapport de 1 pour 13, la modulation $(1 - p_t)^\gamma$ ne compense pas l'a priori. Elle complète une pondération, elle ne la remplace pas. L'**échantillonnage équilibré** stabilise l'AFC mais dégrade significativement l'AFD ($-0,034$, $p = 0,005$), où il répète sans cesse les mêmes 1 200 positifs. Enfin, même avec un encodeur fine-tuné, **l'audio n'apporte rien** (0,357 contre 0,357 et 0,301 contre 0,297).

6.2 Contexte dialogique (n-1, n-2)

Méthode. Le règlement autorise l'utilisation des phrases *précédentes* du débat. MAMKit sait les charger (`with_context`), mais aucun des modèles ne les exploite. Nous les fournissons à RoBERTa sous forme de paire, en ne tronquant que le contexte. La tête et l'entraînement sont ceux de la baseline texte gelée. Tout écart est donc imputable au contexte *et à la manière de l'injecter*.

Entrée texte (RoBERTa gelé)	AFC (F1 macro)	AFD (F1 binaire)
Phrase seule (Partie B)	0,389 $\pm$ 0,040	0,271 $\pm$ 0,005
+ 1 phrase précédente	0,305 $\pm$ 0,033	0,255 $\pm$ 0,005
+ 2 phrases précédentes	0,269 $\pm$ 0,016	0,239 $\pm$ 0,028
+ 1 phrase, moyenne sur la cible seule	0,371	0,269
+ 2 phrases, moyenne sur la cible seule	0,346	0,270
Δ n-1 vs phrase seule [IC 95 %], p	-0,083 [-0,137 ; -0,031], 0,001	-0,016 [-0,047 ; +0,015], 0,31
Δ n-2 vs phrase seule [IC 95 %], p	-0,120 [-0,173 ; -0,064], <0,001	-0,032 [-0,072 ; +0,008], 0,11

Table 6.2 – Effet du contexte dialogique (3 graines ; bootstrap apparié sur 10 000 rééchantillonnages). Les lignes « moyenne sur la cible seule » donnent la moyenne sur 3 graines, sans écart-type.

Le contexte **dégrade significativement l'AFC**, d'autant plus qu'il est long ($-0,08$ avec une phrase, $-0,12$ avec deux), et *Slogans*, la classe la plus courte, s'effondre (F1 de 0,69 à 0,16). En AFD, la baisse n'est pas significative. Nous l'attribuons à l'**injection** du contexte : la baseline moyenne *tous* les tokens, si bien que la

phrase à classer, deux fois plus courte au test, est noyée dans son contexte. Deux contrôles le confirment. Avec l’encodeur gelé mais une moyenne restreinte aux **tokens de la cible**, le score remonte de +0,065 avec une phrase ($p = 0,015$) et de +0,077 avec deux ($p = 0,010$). Avec l’encodeur *fine-tuné*, le contexte $n-1$ ne dégrade plus l’AFC de façon significative (0,363 contre 0,381, $p = 0,57$). Une fois la dilution neutralisée, le contexte n’apporte pourtant **aucun gain** : $n-1$ reste au niveau de la phrase seule ($-0,018$, $p = 0,24$), $n-2$ en dessous ($-0,043$, $p = 0,005$), et l’AFD ne bouge pas. Le bénéfice du contexte rapporté par l’article dépend donc de l’architecture qui le consomme, et demande un modèle capable de *sélectionner* le contexte utile.

6.3 Apprentissage multi-tâche avec la détection de phrases argumentatives

Méthode. Le manque de données AFC est le premier facteur limitant, et Goffredo *et al.* [9] suggèrent que la structure argumentative aide à repérer les sophismes. Nous partageons donc l’encodeur RoBERTa fine-tuné entre la tâche de sophismes et la **détection de phrases argumentatives** (ASD : la phrase contient-elle un *claim* ou une *premise*?) de MM-USED [16], en texte seul. Une tête est dédiée à chaque tâche, la perte vaut $\mathcal{L} = \mathcal{L}_{\text{sophisme}} + \lambda \mathcal{L}_{\text{ASD}}$ avec $\lambda = 0,5$, et chaque pas utilise un lot de chaque tâche. Sur les 23 505 phrases MM-USED, les 1 804 qui appartiennent aux débats de validation ou de test sont retirées : l’encodeur ne les voit jamais. Il en reste 21 701, dont 79 % argumentatives. La référence est un contrôle $\lambda = 0$ exécuté dans *la même boucle d’entraînement* (poids recalculés, sélection sur la perte de validation de la tâche principale).

RoBERTa fine-tuné, poids recalculés	AFC (F1 macro)	AFD (F1 binaire)
Contrôle : tâche principale seule ($\lambda = 0$)	$0,364 \pm 0,030$	$0,311 \pm 0,014$
Multi-tâche sophisme + ASD ($\lambda = 0,5$)	$0,373 \pm 0,014$	$0,299 \pm 0,008$
Δ multi-tâche vs contrôle [IC 95 %], p	+0,009 [−0,023 ; +0,043], 0,57	−0,012 [−0,029 ; +0,005], 0,14
Pour mémoire : même configuration, boucle de la Partie B	$0,381 \pm 0,043$	$0,301 \pm 0,012$

Table 6.3 – Apprentissage multi-tâche (3 graines ; bootstrap apparié).

Le multi-tâche **ne change pas significativement les scores** : +0,009 en AFC ($p = 0,57$, avec un écart-type divisé par deux) et −0,012 en AFD ($p = 0,14$). Deux raisons rendent ce résultat plausible. D’une part, 79 % des phrases de débat sont argumentatives : l’ASD transmet un signal de « registre argumentatif », pas de « défaut de raisonnement ». D’autre part, en AFD, la meilleure époque est atteinte dès la première ou la deuxième passe, avant que la tâche auxiliaire ait pu structurer l’encodeur. Une tâche auxiliaire plus proche du défaut logique, comme les relations d’attaque et de soutien de M-Arg, serait plus pertinente.

6.4 Mécanismes de fusion

Nous avons implémenté cinq fusions de RoBERTa gelé et des trames WavLM (dimension commune 256, 4 têtes, 1 couche), avec la tête et l’entraînement de la baseline. La fusion **précoce** concatène les séquences projetées avant un encodeur commun. La fusion **intermédiaire** utilise un encodeur par modalité puis fusionne les représentations. La fusion **tardive** combine les logits de deux têtes avec des poids appris. L’**auto-attention jointe** porte sur la séquence texte+audio, et l’**attention croisée** fait interroger l’audio par le texte.

Fusion	Param. entraîna- bles	AFC (F1 macro)		AFD (F1 binaire)
		lr 10^{-3} (config)	lr choisi sur la validation	lr 10^{-3}
Concaténation (baseline, Partie B)	0,6 M	0,391 $\pm$ 0,016	–	0,273 $\pm$ 0,004
Précoce	0,43 M	$0,380 \pm 0,048$	$0,380 \pm 0,048$ (10^{-3})	$0,267 \pm 0,012$
Tardive (poids appris)	1,52 M	$0,318 \pm 0,059$	$0,357 \pm 0,002$ (10^{-4})	$0,255 \pm 0,031$
Attention croisée	1,61 M	$0,299 \pm 0,067$	$0,360 \pm 0,033$ ($5 \cdot 10^{-5}$)	$0,254 \pm 0,024$
Intermédiaire	1,61 M	$0,297 \pm 0,039$	$0,332 \pm 0,038$ (10^{-4})	$0,254 \pm 0,021$
Auto-attention jointe	1,02 M	$0,105 \pm 0,053$	$0,190 \pm 0,013$ (10^{-4})	$0,156 \pm 0,110$
Contrôle : branche texte de la fusion tardive seule	0,76 M	$0,340 \pm 0,035$	$0,344 \pm 0,034$ (10^{-4})	$0,259 \pm 0,026$

Table 6.4 – Mécanismes de fusion (3 graines). Taux d’apprentissage candidats en AFC : $\{10^{-3}, 10^{-4}, 5 \cdot 10^{-5}\}$, choisi par modèle sur le F1 de validation moyen.

Au taux de la configuration (10^{-3}), les résultats ne se classent pas selon la *type* de fusion, mais selon la présence d’une *couche d’attention entraînable* : les fusions qui en contiennent une s’effondrent, et l’auto-attention jointe prédit toujours *Ad Hominem* avec deux graines sur trois. Le contrôle « branche texte seule » de la fusion tardive obtient 0,340, soit −0,05 par rapport à la baseline texte, alors que l’ajout de l’audio ne coûte ensuite que

0,02. L'écart vient donc surtout de l'**optimisation**, et non de la fusion.

La recherche du taux d'apprentissage, choisi sur la *validation*, le confirme. Un taux plus faible améliore toutes les fusions à attention (+0,04 en tardive, +0,06 en attention croisée, +0,09 en auto-attention) et réduit fortement leur variance (écart-type de 0,002 en tardive). Pourtant, **aucune fusion ne dépasse la concaténation** (0,391). Toutes les fusions à attention restent même significativement en dessous (tardive $-0,034$, $p = 0,006$; intermédiaire $-0,059$, $p = 0,03$; attention croisée $-0,031$, $p = 0,05$), seule la fusion précoce étant équivalente ($-0,010$, $p = 0,55$). La fusion tardive ne fait pas mieux que sa propre branche texte réglée de la même façon (+0,013, $p = 0,44$) : l'audio n'y apporte rien. L'écart restant avec la baseline texte tient à l'architecture (une couche d'attention sur des tokens gelés au lieu d'une moyenne suivie d'un MLP), et non à l'audio. Enfin, la validation ne désigne pas toujours le meilleur taux pour le test (fusion intermédiaire : 0,332 retenu contre 0,354 possible), une conséquence directe du décalage de distribution (section 4.1).

6.5 Audio seul par cascade parole $\rightarrow$ texte

Si l'information utile est lexicale, un système « audio seul » devrait *transcrire* plutôt que chercher des indices acoustiques. Nous appliquons donc le meilleur modèle texte (RoBERTa fine-tuné avec les poids recalculés, entraîné sur le texte annoté) aux transcriptions Whisper-medium de l'audio du test : l'inférence n'utilise que l'audio. Contrôle : appliqué au texte annoté, chaque modèle rechargé retrouve exactement son score de test (0,4226, 0,3984 et 0,3210).

Système (AFC, test 2024)	F1 macro
Baseline audio WavLM (Partie B)	0,128 $\pm$ 0,043
WavLM gelé moyenné + lecture linéaire (section 6.6)	0,189 $\pm$ 0,010
Cascade Whisper $\rightarrow$ RoBERTa	0,380 $\pm$ 0,045
<i>Référence : même modèle sur le texte annoté</i>	<i>0,381 $\pm$ 0,043</i>

Table 6.5 – AFC à partir de l'audio seul (3 graines).

Lecture. La transcription ne modifie que 5 % des prédictions, et la cascade rejoint presque exactement le modèle sur texte annoté. Elle dépasse de **+0,191** la meilleure représentation acoustique (IC 95 % [+0,120; +0,252], $p < 0,001$), ainsi que le meilleur système audio du shared task (0,356, tableau 2.1). **L'audio contient donc bien l'information nécessaire, mais sous forme *lexicale*** : les modèles acoustiques échouent à exploiter le contenu des mots, et non une prosodie propre aux sophismes. Avec des étiquettes définies sur le texte, la voie la plus efficace pour l'audio passe par la transcription, et une fusion utile devrait apporter une information *complémentaire* à celle-ci.

6.6 Proposition : distillation intermodale texte $\rightarrow$ audio

Motivation et méthode. Entraîné directement sur environ 1 000 étiquettes, l'audio n'apprend rien d'exploitable. Nous testons donc une autre voie : *transférer* la structure de l'espace texte vers l'audio, sans étiquettes, sur toutes les phrases des débats d'entraînement (environ 16 000 paires au lieu de 1 000), avec un modèle qui n'utilise que l'audio à l'inférence. L'approche adapte COMODO [4], une distillation intermodale par file de prototypes conçue pour transférer la vidéo vers des capteurs inertiels, que nous avons déjà adaptée à un autre couple de modalités. L'enseignant est le RoBERTa fine-tuné de la section 6.1 (même graine), gelé et suivi d'un projecteur aléatoire gelé (768 $\rightarrow$ 2048 $\rightarrow$ 128). L'élève est la baseline audio de MAMKit (trames WavLM gelées et encodeur Transformer) suivie d'une tête de projection. Pour chaque paire, la distribution de similarité de l'élève à une file FIFO de $Q = 1024$ projections de l'enseignant (température $\tau_s = 0,05$) est entraînée à reproduire celle de l'enseignant ($\tau_t < \tau_s$), par entropie croisée, avec un gradient vers l'élève seulement (algorithme 1 en annexe). Entraînement : AdamW ($3 \cdot 10^{-4}$, *warmup* de 10 %), lots de 64, au plus 30 époques, sélection de l'époque par une sonde linéaire équilibrée sur la validation AFC, puis lecture du test par une régression logistique équilibrée.

Deux corrections ont été nécessaires. D'abord, les représentations moyennées de RoBERTa sont **anisotropes** (similarité cosinus moyenne d'environ 0,9) : la cible est alors quasi uniforme et la perte reste bloquée à $\ln(1088) \approx 6,99$. Une standardisation z -score, calculée sur les phrases d'entraînement, ramène la similarité à 0,12. Ensuite, τ_t a été choisi sur la *validation* parmi {0,1; 0,05; 0,02}. Avec $\tau_t = 0,02$, la cible place 99,8 % de sa masse sur l'exemple apparié, ce qui revient à un alignement au niveau de l'instance, proche de CLIP [21].

Contrôles. Deux contrôles rendent le résultat interprétable. **raw** moyenne les trames WavLM gelées, sans entraînement, avec la même lecture : il mesure ce que WavLM contient déjà. **Supervisé** entraîne le même élève avec une entropie croisée pondérée sur les étiquettes AFC : il mesure l'apport de l'objectif de distillation. Une lecture sur [raw; élève] teste si l'élève apporte une information *complémentaire*, et une ablation remplace

l’enseignant par un RoBERTa **générique**, non fine-tuné, pour mesurer le rôle de sa connaissance des sophismes. Enfin, une **efficacité en étiquettes** est mesurée : la lecture est ajustée sur 10, 25 et 50 % des étiquettes d’entraînement (sous-échantillons stratifiés, 10 tirages par graine), avec le *même* sous-échantillon pour l’élève et pour raw. C’est le régime où une distillation sans étiquettes est censée aider. Le mode déterministe de PyTorch (cuDNN, cuBLAS) est activé.

Représentation audio (AFC, lecture linéaire)	F1 macro	Par graine (42 / 2024 / 666)	Δ vs raw [IC 95 %], p
Baseline audio MAMKit (Partie B)	$0,128 \pm 0,043$	0,067 / 0,164 / 0,153	–
raw : WavLM gelé moyenné	$0,189 \pm 0,010$	0,175 / 0,200 / 0,191	référence
Élève supervisé	$0,161 \pm 0,005$	0,155 / 0,160 / 0,168	$-0,028$ [$-0,072$; $+0,023$], 0,36
Élève distillé, enseignant générique	$0,167 \pm 0,011$	0,181 / 0,154 / 0,167	$-0,022$ [$-0,069$; $+0,023$], 0,39
Élève distillé, enseignant fine-tuné ($\tau_t = 0,02$)	$0,201 \pm 0,031$	0,244 / 0,188 / 0,170	$+0,012$ [$-0,036$; $+0,056$], 0,62
[raw ; élève distillé fine-tuné]	$0,185 \pm 0,034$	0,230 / 0,177 / 0,148	$-0,004$ [$-0,048$; $+0,037$], 0,89
[raw ; élève supervisé]	$0,168 \pm 0,025$	0,137 / 0,168 / 0,200	$-0,021$ [$-0,064$; $+0,023$], 0,38

Table 6.6 – Distillation texte→audio et contrôles (3 graines, bootstrap apparié sur 10 000 rééchantillonnages). Enseignant fine-tuné contre générique : $\Delta = +0,034$ [$+0,005$; $+0,061$], $p = 0,022$.

Étiquettes AFC pour la lecture	10 % (105)	25 % (264)	50 % (527)
raw : WavLM gelé moyenné	0,166	0,185	0,197
Élève, enseignant fine-tuné	$+0,002$ (57 %)	$-0,004$ (40 %)	$-0,022$ (30 %)
Élève, enseignant générique	$-0,005$ (43 %)	$-0,019$ (30 %)	$-0,030$ (23 %)

Table 6.7 – Efficacité en étiquettes : F1 macro de test de la lecture linéaire pour raw, et écart de l’élève par rapport à raw (entre parenthèses : part des tirages où l’élève gagne ; 3 graines $\times$ 10 sous-échantillons appariés).

Résultat : négatif, mais informatif.

1. **La baseline audio sous-exploite WavLM** : une simple moyenne avec une lecture équilibrée (0,189) la dépasse, avec une variance quatre fois plus faible. Sa faiblesse vient de l’optimisation et du déséquilibre, pas d’un manque d’information dans WavLM.
2. **La distillation ne fait pas mieux que raw**, ni avec toutes les étiquettes ($+0,012$, $p = 0,62$, gain porté par la seule graine 42, celle du choix de τ_t), ni avec peu d’étiquettes (tableau 6.7 : $+0,002$ avec 10 %, puis un léger désavantage). Le régime où la distillation devrait aider ne montre lui non plus aucun gain.
3. **La connaissance de l’enseignant compte, mais elle n’ajoute rien à WavLM**. C’est le seul effet significatif : l’enseignant fine-tuné bat l’enseignant générique de $+0,034$ ($p = 0,022$). S’aligner sur un RoBERTa générique dégrade légèrement les features ($-0,022$) ; s’aligner sur un enseignant qui connaît les sophismes les ramène au niveau de raw. L’élève absorbe donc bien la structure de l’enseignant, mais cette structure ne contient rien que WavLM n’encode déjà.
4. **L’élève n’apporte rien de complémentaire** ([raw ; distillé] $\approx$ raw), et **l’entraînement supervisé dégrade WavLM** : ses dimensions sur-apprises dominent la lecture.
5. **Le résultat est sensible à l’optimisation** : avec des pertes identiques à la quatrième décimale, la graine 42 a donné 0,206 et 0,246 avant le mode déterministe, puis 0,265 et 0,244 lors de deux exécutions déterministes. Un non-déterminisme résiduel du GPU subsiste, et la sélection d’époque l’amplifie. Les valeurs du tableau sont celles de la dernière exécution.

Ce résultat est cohérent avec l’exploration et la cascade : si l’audio ne contient pas d’information acoustique propre aux catégories, l’aligner sur un enseignant texte ne peut que reproduire le contenu lexical que WavLM, affiné pour la transcription, encode déjà. La distillation pourrait devenir utile avec un élève dont les couches hautes sont dégelées, ou sur des données où l’audio participe à l’étiquette.

6.7 Explicabilité du classifieur texte

Méthodes. Nous expliquons le meilleur modèle AFC (RoBERTa fine-tuné, poids recalculés) sur les 229 segments de test et pour les trois graines. Chaque modèle rechargé retrouve exactement son score. Six méthodes donnent un score par mot pour la classe prédite. Deux sont fondées sur l’**attention** : la dernière couche (depuis <s>, moyennée sur les têtes) et l’*attention rollout* [1]. Trois sont fondées sur le **gradient** : sa norme, le produit gradient $\times$ entrée et les gradients intégrés [23], dont la complétude n’est qu’approchée avec 48 pas (écart médian 0,03), ce qui suffit pour classer les mots. La dernière repose sur la **perturbation** : des valeurs de Shapley estimées sur 32 permutations, où un mot absent est supprimé, une approche proche de SHAP [14] dont la somme des valeurs est exacte. Les explications sont *évaluées* selon trois critères. Le premier est leur **fidélité** [6] :

l'*exhaustivité* mesure la baisse de probabilité de la classe prédite quand on supprime les k mots les mieux classés, la *suffisance* cette baisse quand on ne garde qu'eux, et les deux sont comparées à k mots au hasard. Viennent ensuite l'**accord entre méthodes** (Spearman) et la **stabilité entre graines** (Jaccard des 3 mots principaux). Un biais est connu : Shapley est estimé avec la même perturbation que le test de fidélité, ce qui l'avantage.

Méthode ($k = 3$ mots)	Exhaustivité ($\uparrow$)	Suffisance ($\downarrow$)	Stabilité entre graines
Mots au hasard	0,101	0,246	—
Attention (dernière couche)	0,138	0,193	0,71
Attention rollout	0,132	0,206	0,96
Norme du gradient	0,162	0,180	0,73
Gradient $\times$ entrée	0,078	0,255	0,33
Gradients intégrés	0,184	0,181	0,32
Shapley (permutations)	0,280	0,096	0,44

Table 6.8 – Fidélité (baisse de probabilité de la classe prédite) et stabilité (Jaccard des 3 mots principaux entre deux graines) des explications (AFC, test, moyenne sur 3 graines ; courbes en annexe, figure B.3).

Fidélité, accord et stabilité.

1. **L'attention n'est pas une explication fiable.** Supprimer les 3 mots qui reçoivent le plus d'attention ne fait baisser la probabilité que de 0,138, contre 0,101 pour 3 mots au hasard, et 0,280 avec Shapley. Gradient $\times$ entrée fait même *moins bien* que le hasard : le produit est dominé par la norme des embeddings, et non par leur effet sur la décision.
2. **Les méthodes s'accordent peu** : Spearman de 0,56 entre les deux attentions, mais 0,31 seulement entre les gradients intégrés et Shapley, et proche de 0 entre l'attention et gradient $\times$ entrée. Montrer une seule carte de chaleur non validée revient à choisir arbitrairement une explication parmi d'autres.
3. **Fidélité et stabilité s'opposent.** La méthode la plus stable entre graines (rollout, 0,96) est parmi les moins fidèles, et les plus fidèles (Shapley, gradients intégrés) varient beaucoup (0,32 à 0,44). Ce n'est pas un défaut des méthodes : les trois modèles ne prédisent la même classe que pour 76 à 78 % des segments, et à scores comparables, **ils s'appuient sur des mots différents**. Une explication stable mais peu fidèle reflète la structure de l'encodeur, pas la décision.

Ce que le modèle a appris. Le lexique des gradients intégrés (figure B.4 et exemples en annexe) est cohérent avec les définitions des classes. Il fait aussi apparaître des raccourcis :

- *Appeal to Emotion* repose sur un vocabulaire affectif (« dying », « terrible », « dangerous », « crime ») ;
- *Appeal to Authority* sur des sources citées (« governor », « professors », « endorsed », « former ») ;
- *Slogans* sur une formule mémorisée (« make America great again ») ;
- *Ad Hominem*, en revanche, est prédit sur la **simple mention de l'adversaire** : pronoms (« she's », « you're »), noms et étiquettes politiques (« Putin », « China », « marxist »).

Ce raccourci explique la confusion la plus fréquente, avec les mêmes mots en cause : 92 *Appeal to Emotion* sont prédits *Ad Hominem*. La deuxième confusion, vers *Slippery Slope* (35 cas, alors que la classe est absente du test), est portée par des marqueurs de conséquence future (« decline », « destroyed », « if »). *False Cause*, enfin, n'a aucun mot fortement attribué (« economy », « inflation », « because », avec des scores faibles). Ce sophisme se joue dans la relation entre deux propositions, pas dans le vocabulaire, ce qui explique les très faibles scores de la classe. Pour la thèse, la piste est concrète : contraindre *Ad Hominem* à porter sur une attaque, et non sur une simple mention, demande des rationales annotées ou des contre-exemples ciblés.

7 Discussion, limites et perspectives

7.1 Synthèse

1. **La reproduction est fidèle, à condition de corriger la chaîne.** Une fois les quatre défauts de la section 3.5 corrigés, nos six scores se situent dans la variabilité entre graines des scores publiés. Sans ces corrections, l'AFC aurait été mesurée par l'*accuracy*, et le F1 AFD calculé sur des étiquettes inversées.
2. **L'information est lexicale ; l'acoustique n'apporte rien de plus.** Cinq observations convergent : le texte+audio égale le texte seul, aucune fusion ne dépasse la concaténation (même après réglage du taux d'apprentissage), le fine-tuning ne rend pas l'audio utile, la prosodie normalisée ne distingue pas les classes, et la distillation ne dépasse pas une moyenne de WavLM, même lorsque peu d'étiquettes sont disponibles. À l'inverse, la cascade Whisper→RoBERTa obtient à partir de l'audio seul le score du texte annoté (0,380

contre 0,381). Avec des étiquettes définies par le texte, l’audio vaut ce que vaut son contenu lexical, et une fusion utile doit apporter autre chose que ce que la transcription contient déjà.

3. **La manière d’utiliser une information compte autant que l’information.** Le fine-tuning aide significativement la détection. En revanche, les fusions à attention échouent d’abord pour des raisons d’optimisation et restent, même réglées, significativement sous la concaténation. Le contexte moyenné avec la cible dans un encodeur gelé dilue celle-ci ($-0,08$ à $-0,12$) : ne moyenner que la cible annule l’essentiel de la baisse, mais ne fait apparaître aucun gain. Le multi-tâche avec la détection de phrases argumentatives ne change rien de significatif.
4. **Les explications doivent être évaluées avant d’être montrées.** L’attention est à peine plus fidèle que le hasard, les méthodes fidèles sont instables d’une graine à l’autre, et le raccourci « mention de l’adversaire $\rightarrow$ *Ad Hominem* » explique la confusion la plus fréquente.
5. **La variance est le premier obstacle à des conclusions fiables.** La dispersion entre graines (jusqu’à 0,19 entre la meilleure et la pire graine en AFC fine-tuné) et entre exécutions « identiques » (0,06 pour la distillation, encore 0,02 avec le mode déterministe) dépasse la plupart des effets étudiés. Sur ce test, une comparaison fondée sur un seul entraînement n’a pas de valeur probante.

7.2 Limites

Trois graines restent peu, et chaque graine fixe à la fois l’initialisation et la validation. Les bootstraps appariés mesurent l’incertitude due au test, pas la variance d’entraînement : avec 229 exemples, seuls des écarts d’environ 0,05 sont détectables. La recherche d’hyperparamètres des fusions se limite à trois taux d’apprentissage, en AFC. Seule la Baseline Transformer a été reproduite. Enfin, la distillation n’a été évaluée qu’avec un WavLM gelé, et uniquement en AFC.

7.3 Perspectives

- **Annotations multimodales.** C’est la condition pour que l’audio compte : annoter avec l’audio les procédés où la manière de dire fait partie de la stratégie (emphase, ironie, interruption, montée émotionnelle). L’accord inter-annotateurs (0,22 pour *False Cause*) montre que la définition même des catégories reste fragile.
- **Intégrer la modalité vidéo.** Les sources dont MAMKit extrait l’audio contiennent aussi l’image. Or une part importante de la stratégie rhétorique passe par le non-verbal : expressions faciales, regard, gestes de désignation de l’adversaire, posture, réactions de l’interlocuteur pendant qu’il est attaqué. Ces indices sont précisément ceux qui manquent à nos résultats. Nous avons montré que l’audio n’apporte ici que son contenu lexical (section 6.5), alors que la vidéo porte une information que la transcription ne contient pas. Elle est donc candidate à une contribution réellement *complémentaire* au texte, en particulier pour *Ad Hominem* (mépris, désignation de l’adversaire) et *Appeal to Emotion* (expression de l’indignation ou de la peur). Les horodatages par mot permettent d’aligner chaque phrase sur ses images. Cette hypothèse se teste avec le même protocole que l’audio (contrôles, tests appariés) ; elle suppose elle aussi des annotations où l’image participe à la définition de l’étiquette.
- **Fusion guidée par l’alignement.** Le jeu de données fournit des horodatages par mot. Une attention croisée où chaque mot n’interroge que ses propres trames exploite une structure qu’aucune fusion testée n’utilise, avec beaucoup moins de paramètres à apprendre.
- **Locuteur et interaction.** Les indices acoustiques dépendent du locuteur [12]. Une normalisation par locuteur (via diarisation, fautes d’identifiants) et une modélisation des tours de parole (réponses, interruptions) sont plus prometteuses que des descripteurs isolés par phrase. La vidéo faciliterait d’ailleurs l’identification du locuteur à l’écran.
- **Tâches auxiliaires, décision, explicabilité.** Exploiter les relations argumentatives (M-Arg), calibrer le seuil AFD sur la validation, et confronter les attributions à des rationales annotées, en n’utilisant que des méthodes dont la fidélité a été vérifiée.

7.4 Conclusion

Nous avons reproduit les baselines Transformer de MM-ArgFallacy2025 sur le test officiel après avoir corrigé quatre défauts de la chaîne de traitement, et montré que la variabilité entre graines explique la plupart des écarts commentés dans l’article. Huit extensions, évaluées à protocole constant et avec des contrôles, convergent : le facteur limitant n’est pas l’architecture de fusion, mais la nature des étiquettes et la taille des données. L’audio n’est pas vide pour autant : transcrit, il égale le texte annoté et dépasse tous les systèmes audio du shared task. Son information est lexicale, non prosodique. Nous recommandons des tests appariés sur plusieurs graines, une annotation qui intègre l’audio et une fusion alignée au niveau du mot.

Bibliographie

- [1] Samira Abnar and Willem Zuidema. Quantifying attention flow in transformers. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 4190–4197, 2020.
- [2] Max Bain, Jaesung Huh, Tengda Han, and Andrew Zisserman. WhisperX : Time-accurate speech transcription of long-form audio. In *Interspeech 2023*, pages 4489–4493, 2023.
- [3] Taylor Berg-Kirkpatrick, David Burkett, and Dan Klein. An empirical investigation of statistical significance in NLP. In *Proceedings of the 2012 Joint Conference on Empirical Methods in Natural Language Processing and Computational Natural Language Learning*, pages 995–1005, 2012.
- [4] Baiyu Chen, Wilson Wongso, Zechen Li, Yonchanok Khaokaew, Hao Xue, and Flora Salim. COMODO : Cross-modal video-to-IMU distillation for efficient egocentric human activity recognition. *arXiv preprint arXiv :2503.07259*, 2025.
- [5] Sanyuan Chen, Chengyi Wang, Zhengyang Chen, Yu Wu, Shujie Liu, Zhuo Chen, Jinyu Li, Naoyuki Kanda, Takuya Yoshioka, Xiong Xiao, et al. WavLM : Large-scale self-supervised pre-training for full stack speech processing. *IEEE Journal of Selected Topics in Signal Processing*, 16(6) :1505–1518, 2022.
- [6] Jay DeYoung, Sarthak Jain, Nazneen Fatema Rajani, Eric Lehman, Caiming Xiong, Richard Socher, and Byron C. Wallace. ERASER : A benchmark to evaluate rationalized NLP models. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 4443–4458, 2020.
- [7] Bradley Efron and Robert J. Tibshirani. *An Introduction to the Bootstrap*. Chapman and Hall/CRC, 1994.
- [8] Pierpaolo Goffredo, Mariana Chaves, Serena Villata, and Elena Cabrio. Argument-based detection and classification of fallacies in political debates. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 11101–11112, 2023.
- [9] Pierpaolo Goffredo, Shohreh Haddadan, Vorakit Vorakitphan, Elena Cabrio, and Serena Villata. Fallacious argument classification in political debates. In *Proceedings of the Thirty-First International Joint Conference on Artificial Intelligence (IJCAI)*, pages 4143–4149, 2022.
- [10] Zhijing Jin, Abhinav Lalwani, Tejas Vaidhya, Xiaoyu Shen, Yiwen Ding, Zhiheng Lyu, Mrinmaya Sachan, Rada Mihalcea, and Bernhard Schölkopf. Logical fallacy detection. In *Findings of the Association for Computational Linguistics : EMNLP 2022*, pages 7180–7198, 2022.
- [11] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. Focal loss for dense object detection. In *IEEE International Conference on Computer Vision (ICCV)*, pages 2999–3007, 2017.
- [12] Marco Lippi and Paolo Torroni. Argument mining from speech : Detecting claims in political debates. In *Proceedings of the Thirtieth AAAI Conference on Artificial Intelligence*, pages 2979–2985, 2016.
- [13] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. RoBERTa : A robustly optimized BERT pretraining approach. *arXiv preprint arXiv :1907.11692*, 2019.
- [14] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems 30*, pages 4765–4774, 2017.
- [15] Eleonora Mancini, Federico Ruggeri, Stefano Colamonaco, Andrea Zecca, Samuele Marro, and Paolo Torroni. MAMKit : A comprehensive multimodal argument mining toolkit. In *Proceedings of the 11th Workshop on Argument Mining (ArgMining 2024)*, pages 69–82. Association for Computational Linguistics, 2024.
- [16] Eleonora Mancini, Federico Ruggeri, Andrea Galassi, and Paolo Torroni. Multimodal argument mining : A case study in political debates. In *Proceedings of the 9th Workshop on Argument Mining*, pages 158–170, 2022.
- [17] Eleonora Mancini, Federico Ruggeri, and Paolo Torroni. Multimodal fallacy classification in political debates. In *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics (Volume 2 : Short Papers)*, pages 170–178, 2024.
- [18] Eleonora Mancini, Federico Ruggeri, Serena Villata, and Paolo Torroni. Overview of MM-ArgFallacy2025 on multimodal argumentative fallacy detection and classification in political debates. In *Proceedings of the 12th Workshop on Argument Mining (ArgMining 2025)*, pages 358–368. Association for Computational Linguistics, 2025.
- [19] Rafael Mestre, Stuart E. Middleton, Matt Ryan, Masood Gheasi, Timothy Norman, and Jiatong Zhu. Augmenting pre-trained language models with audio feature embedding for argumentation mining in political debates. In *Findings of the Association for Computational Linguistics : EACL 2023*, pages 274–288, 2023.
- [20] Rafael Mestre, Razvan Milcin, Stuart E. Middleton, Matt Ryan, Jiatong Zhu, and Timothy J. Norman. M-Arg : Multimodal argument mining dataset for political debates with audio and transcripts. In *Proceedings of the 8th Workshop on Argument Mining*, pages 78–88, 2021.
- [21] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *Proceedings of the 38th International Conference on Machine Learning*, pages 8748–8763, 2021.
- [22] Alec Radford, Jong Wook Kim, Tao Xu, Greg Brockman, Christine McLeavey, and Ilya Sutskever. Robust speech recognition via large-scale weak supervision. In *Proceedings of the 40th International Conference on Machine Learning*, pages 28492–28518, 2023.

- [23] Mukund Sundararajan, Ankur Taly, and Qiqi Yan. Axiomatic attribution for deep networks. In *Proceedings of the 34th International Conference on Machine Learning*, pages 3319–3328, 2017.
- [24] Yao-Hung Hubert Tsai, Shaojie Bai, Paul Pu Liang, J. Zico Kolter, Louis-Philippe Morency, and Ruslan Salakhutdinov. Multimodal transformer for unaligned multimodal language sequences. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pages 6558–6569, 2019.

A Code source et reproduction

Le code de toutes les expériences de ce rapport, les instructions d’installation et de reproduction, ainsi que les commandes de chaque expérience sont disponibles dans le dépôt Git qui accompagne ce rapport :

https://github.com/Moez2kessemtini/MM_argfallacy_implementation

Environnement : Python 3.10, PyTorch 2.3.0 (CUDA 12.1), deux GPU NVIDIA L40S. MAMKit est utilisé sans modification ; les correctifs de la chaîne de traitement (section 3.5) sont appliqués dans notre code.

Débats de validation par graine. Graine 42 : 29_2004, 39_2012, 42_2016, 44_2020. Graine 2024 : 3_1960, 4_1960, 9_1980, 44_2020. Graine 666 : 7_1976, 18_1992, 41_2016, 43_2016.

B Compléments

B.1 Défauts de la chaîne de traitement

Défaut	Constat	Correction
F1 « macro » calculé en <i>micro</i>	<code>torchmetrics.F1Score(task='multiclass')</code> utilise <code>average='micro'</code> par défaut, y compris dans les démos AFC. Le score obtenu est alors l' <i>accuracy</i> . Indice qui nous a alertés : $F1 \times 229$ tombait toujours sur un entier.	<code>average='macro'</code> explicite
Étiquettes AFD inversées sur le test	Les phrases non fallacieuses de 2024 ont <code>fallacy = NaN</code> , et non <code>None</code> . Le test <code>label is not None</code> les classe donc comme « sophisme » : 2160 positifs au lieu de 229.	<code>NaN→None</code> ; filtre AFC sur les étiquettes définies
Recherche de configuration instable	<code>ConfigKey.__hash__</code> hache <code>str(set)</code> , dont l’ordre varie d’un processus à l’autre, d’où des <code>KeyError</code> aléatoires (17 essais sur 60 en faisant varier <code>PYTHONHASHSEED</code>).	Recherche par égalité
Dépendance à l’état aléatoire	Le chargement de WavLM consomme le générateur aléatoire entre la fixation de la graine et l’initialisation de la tête. Les résultats audio et texte+audio dépendaient donc de la présence ou non d’un cache de caractéristiques (AFC audio : 0,067 contre 0,124).	Nouvelle fixation de la graine après le prétraitement

Table B.1 – Défauts identifiés lors de la reproduction.

B.2 Exploration : prosodie et alignement




Figure B.1 – Descripteurs prosodiques par classe AFC, centrés et réduits au sein de chaque débat.




Figure B.2 – Audit de l’alignement : précision et rappel lexicaux par extrait, taux d’erreur de mots (WER) de Whisper et répartition des catégories par classe.

B.3 Pseudo-code de la distillation texte→audio

Algorithme 1 Distillation texte→audio par file de prototypes (un pas d’entraînement)

Entrées : lot de paires $(x_i^{\text{txt}}, x_i^{\text{aud}})_{i=1..B}$, file $\mathcal{Q} \in \mathbb{R}^{Q \times d}$, températures $\tau_t < \tau_s$

- 1: $t_i \leftarrow \text{norm}(P_t(\text{std}(T(x_i^{\text{txt}}))))$ ▷ enseignant gelé, standardisé
 - 2: $s_i \leftarrow \text{norm}(P_s(S(x_i^{\text{aud}})))$ ▷ élève entraînable
 - 3: $\mathcal{B} \leftarrow [\mathcal{Q}; t_{1..B}]$
 - 4: $p_i \leftarrow \text{softmax}(t_i \mathcal{B}^\top / \tau_t)$, $q_i \leftarrow \text{softmax}(s_i \mathcal{B}^\top / \tau_s)$
 - 5: $\mathcal{L} \leftarrow -\frac{1}{B} \sum_i \sum_j p_{ij} \log q_{ij}$ ▷ gradient vers l’élève seulement
 - 6: $\mathcal{Q} \leftarrow$ les Q dernières lignes de $\mathcal{B}$ ▷ mise à jour FIFO
-

B.4 Explicabilité : fidélité, lexique et exemples




Figure B.3 – Fidélité des six méthodes en fonction du nombre k de mots supprimés ou conservés.




Figure B.4 – Mots les plus attribués par classe prédite (gradients intégrés, 3 graines, mots grammaticaux exclus).

Exemples. Un même segment expliqué par les six méthodes (rouge : vers la classe prédite ; bleu : contre, pour les méthodes signées) :

Vrai : Appeal to Emotion ; prédit : Appeal to Emotion ($p = 0.59$)

Attention (dernière couche)	We had the greatest economy in the history of our country.
Attention rollout	We had the greatest economy in the history of our country.
Norme du gradient	We had the greatest economy in the history of our country.
Gradient $\times$ entrée	We had the greatest economy in the history of our country.
Gradients intégrés	We had the greatest economy in the history of our country.
Shapley (permutations)	We had the greatest economy in the history of our country.

Vrai : Appeal to Emotion ; prédit : Ad Hominem ($p = 0.46$)

Attention (dernière couche)	I went to the World War II cemetery, World War I cemetery he refused to go to.
Attention rollout	I went to the World War II cemetery, World War I cemetery he refused to go to.
Norme du gradient	I went to the World War II cemetery, World War I cemetery he refused to go to.
Gradient $\times$ entrée	I went to the World War II cemetery, World War I cemetery he refused to go to.
Gradients intégrés	I went to the World War II cemetery, World War I cemetery he refused to go to.
Shapley (permutations)	I went to the World War II cemetery, World War I cemetery he refused to go to.

Les deux exemples illustrent les constats de la section 6.7. L'attention, sous ses deux formes, se concentre sur le dernier token (« country. », « to. ») : elle suit la structure de la séquence, pas la décision. Dans le second exemple, mal classé, les gradients intégrés et Shapley désignent « he refused » comme responsable de la prédiction *Ad Hominem*. Le modèle réagit à la mention de l'adversaire, et non à une attaque contre sa personne, alors que le segment est en réalité un appel à l'émotion. Gradient $\times$ entrée, enfin, attribue des signes opposés aux autres méthodes, ce qui est cohérent avec sa faible fidélité.